场景设计方案

6G 链路自适应家庭 AI 推理系统

系统代号 SenseHome

场景类型 面向实际需求的应用场景设计方案

版本 2026 年 11 月 11 日

作品简介

家庭智能体调用远程模型时，网络、模型负载与输出合规共同决定任务能否完成。SenseHome 面向存量住宅集成服务，设计设备规则、网关模型和远程模型三档能力，以纯 C 策略联合使用 WAN/LAN 及两端服务观测选择后端，执行动作白名单、故障回退和事件记录。融合版 r3 完成全量构建与审计，复杂任务合成时限内合同完成率为联合 84.40%、仅网络 62.98%；无迟滞 84.52%，不支持迟滞提升完成率。本轮 20 条冻结命令、四臂、三次重复产生 240 条本机记录。每臂 21 次复杂模型请求中，联合、仅网络和固定小模型均 15 次非空模拟执行完成，第二本机 4B 候选也是 15 次；正常健康条件下未证明联合优势。独立历史 AutoDL 真实模型动作一致 17/20。各来源分别统计，当前设备为 PC 模拟状态，双模型共享本机 GPU，无真实家庭、物理执行或 6G 空口证据。方案以可解释降级与可复核记录为基础，后续逐层验收需求、独立部署、网络和成本。

当前成熟度 软件原型与分层验证，真实家庭与物理设备尚未试点。

一 场景概述与需求来源

目标业务

目标使用者是为存量住宅接入灯光、窗帘和环境设备的集成服务商，最终使用者是住户。集成商需要在网络或模型异常时定位故障、保留可执行操作，并清楚解释能力变化。该客户画像是设计定位，尚无具名客户确认、访谈记录或试点证明。

业务问题

远程模型路径依赖广域网与上游服务。WAN 故障时，LAN 和本地设备控制可能仍可用；模型可连接时，也可能因排队、内存不足或输出不合规而不能执行。系统因此分别管理链路、服务与动作边界，避免把收到 HTTP 响应直接计作任务完成。

问题	设计响应	验收观察
WAN 异常但 LAN 可用	保留网关模型候选和设备规则	路由原因与实际后端
模型繁忙或观测过期	检查两端资源与观测年龄	拒选原因和 unknown 字段
复杂或危险动作	整项校验和失败闭锁	动作计划、拒绝原因、状态差异

公开依据与直接证据

Home Assistant 官方 Assist、本地 pipeline、Ollama 与 AI agent 文档表明，本地自然语言、模型接入和本地意图优先均已有实现，不能作为本作品首创。RouteLLM 已有成本与质量驱动的模型路由。ITU-R M.2160-0 与 ETSI MEC 支持通信计算协同和边缘信息接口方向。上述官方材料支持技术背景，不代表住户需求、客户愿付价或本项目性能优势。9 项来源的 URL、摘录、访问日期和哈希见 docs/value/public_sources.json。

二 需求指标与证据口径

KPI 按证据层分别验收。同一指标必须同时给出输入、样本数、完成定义和计时边界，禁止混合合成时延、HTTP 墙钟和真实模型接口时延。

指标	当前核验结果	适用层
时限内完成固定规划合同	joint 84.40%，network-only 62.98%，每臂复杂任务 n=5,040	r3 合成回放
HTTP 复杂任务达标	矩阵 joint/network-only 80.95%/61.90%；压力组 52.98%/52.54%	本机规划桩墙钟
模型参考动作一致	17/20，85.0%；请求 p50 290.679 ms、p95 522.643 ms	独立 AutoDL 历史真实推理
本机四臂真实模型	240 条；各臂复杂任务非空完成 15/21	本机共享 GPU；规则单列
本地控制与状态确认	开关灯 p95 最大 4.434 ms；只读安防查询 1.711 ms；合计 160 次确认	旧版 PC 模拟设备
动作白名单边界	28 项通过，25 项拒绝、3 项正向控制	隔离 PC 安全用例
目标部署与用户价值	真实家庭、物理动作、成本和 6G 空口待验收	设计阶段

完成定义

接口成功表示请求收到了约定响应。合成合同完成表示规划桩满足指定合同。真实模型动作一致根据冻结参考动作核对，拒绝原因另列。PC 状态确认是模拟 JSON 设备状态变化。真实物理执行还需设备回执或传感器确认，当前没有该层证据。

原 K1/K2 为旧网络策略的时延目标，实测未达标；旧正常档 405.6 ms、劣化档 596.2 ms 不归因于 r3。后续真实端到端目标需由需求方确认并绑定硬件、模型和网络条件。

三 总体架构与业务流程

设备端规则、模型网关和远程模型是独立部署角色。当前统一网关运行在普通PC，设备由JSON状态模拟；QEMU原型与Dashboard软件通道分别说明。

部署角色	职责	当前实现与接口
命令入口	接收指令、展示结果与原因	Dashboard /api/command
PC网关	观测适配、调用C策略、后端请求、记录事件	Python；健康缓存；policy_cli
唯一策略实现	任务约束、候选可用性与代价、恢复迟滞	offload_policy.c，结构化输入输出
模型候选	本地模型或远程模型动作规划	wrapper /infer；本机OpenAI兼容直连接口
设备边界	校验允许动作并确认状态	Python动作白名单；PC JSON状态

一次请求的处理

先识别任务类别。支持的结构化控制和只读安全查询直接使用本地规则，绕过同步网络探测。复杂指令读取WAN/LAN与两端算力快照，交由C策略选择候选；模型计划经过schema与权威白名单检查后执行。后端异常、输出不合规或候选不可用时按边界回退，事件保存原因、耗时、能力标志和状态。

适配与兼容

策略核心使用纯C。完整网关依赖Python、HTTP与子进程，目标RTOS需适配计时、网络、IPC和设备API。QEMU的C白名单与Dashboard的Python检查是两套实现，不能称作同一条已验证通道。现有设备工具可保留，但每次平台迁移仍需独立验收。

三 联合路由与 AI 加 6G 映射

两段链路与两端算力

WAN 和 LAN 分别建模。复杂请求首先排除模型未就绪、观测过期或资源超限的候选，再比较已知的网络、排队和推理预算。带宽可用时才加入传输估算，未知字段保持 unknown。切换裕量与恢复样本数是项目配置，不是 6G 标准。Python 仅适配观测和执行请求，决策以 C 实现为准。

融合方向	当前软件机制	未来接入与验证
网络支持 AI	链路预算进入模型位置选择	接真实链路遥测，比较尾时延与完成率
AI 任务支持协同	安全、结构化、复杂任务分级	测减少的远端调用与传输量
算力与网络联合	模型健康、队列、内存、并发参与候选检查	接真实资源采集并校准代价
运行可追溯	原因码、观测来源、事件 ID 和错误分层	真实设备回执与访问控制

差异化与技术边界

端云路由已有广泛研究，家居平台也已有本地自动化。本作品的具体交付是家庭两段链路、三档能力、C 策略唯一实现及可审计证据流水线。当前未实现 6G 空口、网络切片、确定性承载或无线资源分配，也没有证明算法最优。6G 相关能力是可替换的未来观测和承载接口，不能由软件桩的结果推导网络标准性能。

四 融合版 r3 验证

r3 于 2026 年 11 月 11 日新加坡时间完成全量验证，Zig 0.17.1 cc 前端构建，quick_mode=false，记录源码运行期间未变化。归档 328 个运行文件与原验证目录逐路径 SHA256 一致。

验证范围	样本或测试	结果
C 网络策略 / 算力策略	70 / 17	全部通过
网关 / Dashboard / 部署	139 / 37 / 25 项	全部通过
合成 replay	58,800 条	完整矩阵与审计通过
并发 / 敏感性	6,144 / 9,360 条	本机墙钟 / 12 个单因素变体
安全 / HTTP 网关	28 项 / 9,084 请求	用例与持久化事件审计通过

复杂任务结果

策略臂	n	时限内合同完成
双端联合 joint	5,040	84.40%（4,254/5,040）
仅网络 network-only	5,040	62.98%
仅算力 compute-only	5,040	61.90%
无迟滞 no-hysteresis	5,040	84.52%

联合策略仍有 786 条 UNRESOLVED_NO_NLU。无迟滞达标率略高，不支持“迟滞提高完成率”。指定轨迹中 joint 切换 93 次、无迟滞 207 次，仅证明该轨迹中的切换计数差异。上述指标来自合成输入和固定规划桩，不能解释为语言理解准确率或用户体验收益。

复核入口

SenseHome-6G/evidence/network_compute/20261111_fused/README.md；replay/summary.json；validation/verification.json。

四 HTTP 网关与安全闭环

独立 HTTP 墙钟实验

HTTP 实验包含 2,940 条矩阵请求和 6,144 条压力请求，共 9,084 条请求与持久化事件。矩阵复杂任务 joint/network-only 时限达标 80.95%/61.90%；压力组 52.98%/52.54%，压力条件下差距很小，不能概括成稳定的大幅收益。

观察	数量	解释
外层 HTTP 响应 200	9,084	表示接口响应，不表示业务完成
合同未完成	679	383 条合同未完成及 296 条注入 503
下游 HTTP_503	296	应用层故障注入，并非实网丢包
HTTP 文件清单	283 项	SHA256 匹配

白名单与故障处理

28 个安全用例全部通过，其中 25 项应拒绝输入被拒绝，3 项为允许动作正向控制。检查递归扫描嵌套字段；不合规动作整项拒绝，避免执行部分危险计划。超时、畸形 JSON、策略进程异常、fallback 异常和并发回归留有结构化错误记录。

测试范围内的拒绝证明特定防护有效，不能推导任意 prompt injection 或真实物理风险已消除。燃气、门禁等未授权动作不执行；真实部署仍须设备联锁、鉴权、TLS、响应大小限制、访问控制与日志脱敏。

复核入口 SenseHome-6G/evidence/network_compute/20261111_fused/http_gateway/；safety/；validation/。

四 独立真实模型证据

2026 年 11 月 3 日已完成 AutoDL 真实模型推理。模型为 Qwen2.5-1.5B-Instruct 固定 revision，vLLM 0.33.0，RTX 4080 SUPER。20 条命令各推理一次，few-shot 提示与透明动作归一化均保留原始输出。该历史实验尚未与 r3 联合策略端到端联测。

指标	核验结果	计量边界
HTTP 成功	17/20	三条 422 保护拒绝单列
参考动作一致	17/20（85.0%）	使用冻结参考动作
请求时延 p50 / p95	290.679 / 522.643 ms	该模型接口请求墙钟
预期拒答	3/3 另行记录	不并入普通成功率
设备执行	未包含	模型动作规划级

保护层与模型输出分别记录

A01/A02 产生未提及房间的动作，保护层返回 422；A04 阳台动作不在白名单，返回 422。这三条属于 fail-closed 保护拒绝，不能改写为成功响应。原始报告 eval.draft.json 保留；eval.formal.json 是标签冻结后对已捕获真实响应的重新标注，并非重新推理。

与本轮证据的关系

本轮另有 240 条本机四臂联测，使用新日期、共享本机模型与独立来源记录，详见下一页。历史 AutoDL 的模型、运行时和环境不同，二者不合并为更大的准确率或时延样本。

复核入口 docs/experiments/autodl_20261103_normalized_v2/README.md、eval.formal.json、eval.draft.json；docs/deployment/20 条动作标签冻结记录_20261103.json。

四 本机真实模型四臂联测

正式运行：2026 年 11 月 11 日，20 条冻结人工标签×3 次重复×4 臂，共 240 条；运行器失败 0、跳过 0。相同命令、上下文、初始状态和冻结健康快照，策略臂顺序轮换；各臂均让简单与安全类任务使用本地规则。

复杂模型臂	结构匹配	非空完成	保护拒绝	网关 p50 / p95 ms
fixed-local	15/21	15/21	6	617.349 / 5995.330
fixed-cloud 代理	18/21	15/21	3	635.609 / 1402.547
network-only	15/21	15/21	6	627.756 / 4097.427
joint	15/21	15/21	6	632.459 / 1284.334

每臂另 39 条规则请求，结构 39/39 匹配，其中 21 条非空模拟完成、18 条空结构匹配，不解释为澄清正确。复杂模型上游 HTTP 与保护拒绝分列。固定 4B 的结构匹配包含空结构，不能直接解释为非空完成。

本机条件下的结论

Qwen2.5-1.5B 与 Qwen3-4B 均为 Q4_K_M 量化，共享本机 GPU；fixed-cloud 只是第二端点代理，不是真实两地端云。未知 revision 保持 unknown。正常健康条件没有证明联合优势，不能复现 r3 合成达标收益。

时延为网关墙钟，共享探测在网关外单列；HTTP 清单往返不是无线 RTT。重复行相关，仅作描述统计。正式运行来源见附录“本机联测”，源码与既有 C 二进制哈希分别保存。

四 实施路径与验收里程碑

阶段	交付与验收	当前状态
软件与融合策略	C 构建、测试、unknown 闭锁、事件、全量实验审计	已完成 r3 归档
真实模型独立验证	固定模型配置、冻结标签、逐条响应、拒绝与时延	已有历史 20 条
本机联合评测	同集四臂、原始失败、端到端计时、资源观测	已完成 240 条正式联测
需求采集	集成商或住户知情同意、逐题原话、KPI 确认	尚无真实回答
目标设备与网络	授权设备、真实链路、重复尾时延和回执	未开展
试用与推广	至少明确一类目标客户，验证安装工时与维护成本	后续依验收推进

可靠性验收

新增模型和硬件先在隔离设备状态中运行，保留模型原始计划与归一化后的动作。网络故障、模型超时、输出错误和执行错误分别注入并核对。真实硬件接入需验证断连恢复、重复命令幂等和安全联锁，未经授权不接入危险执行器。

用户试用与隐私

试用工具包含知情同意、家庭控制任务、异常情景和反馈表。用户回答需保留日期、角色、任务及原话，公开材料匿名化，不采集住址或敏感家庭习惯。尚未收到真实回答的表格保持待采集状态，不生成用户证言。

生产环境须设置日志脱敏、访问权限与留存周期。网关本地部署不自动意味着数据不出户；每项任务是否发送模型端、发送字段和保存位置均需明确。

五 产业价值与推广

可量化价值与适用客户

优先面向已有本地模型运行条件的家居集成商和开发者，提供统一策略、设备适配和可复核故障记录。价值验收重点是合同完成率、尾时延、远端调用、故障定位时间和部署维护工时。当前实验支持软件机制的可运行性，尚未产生住户体验改善或实际商业收入证据。

价值指标	采集方法	当前证据
服务连续性	同输入比较成功、拒绝与能力降级	合成和 HTTP 桩已有
运维效率	记录诊断前后人工工时与问题类型	暂无客户实测
部署资源	进程 RSS、显存、功耗、冷启动和并发	逐机测量，不用 MCU 对象替代
成本收益	计算实际推理费、电费与维护费	报价参数和情景假设单列

成本核算与复制条件

成本工具按硬件摊销、电费、云 token、维护和网络费用分项，输入标记实测、报价、假设或未知。月总成本 C=P/M+E×电价+云 token 费+维护+网络，每千总请求成本为 1000C/N。任一必要分项缺失时，总成本保持 null。现无采购价、电表积分或实际维护工时，不能给出实测节费比例。历史 28.1 KB 仅为端侧目标对象，不是完整网关或模型内存。

复制包包含 C 策略、HTTP 合同、设备适配、固定输入、原始事件及版本清单。每个目标平台重新校准模型容量、时延预算、动作权限和协议兼容。先验证单类灯光与只读查询，再扩展到窗帘和环境设备；真实高风险设备需专业测试。

六 单人实施与资源保障

现有能力和组织方式

当前由一名学生负责业务建模、C 策略、Python 网关、测试和材料。采用需求与指标、实现与构建、实验与审计、材料与发布四条任务清单管理依赖和版本。代码变更后重新构建相关证据，发布前交叉核对数字、引用和文件哈希，不虚构三人团队或合作单位。

资源与依赖

本轮只使用现有 Windows PC，无新租云。30 样本基线中，小模型和大模型进程 RSS 中位分别为 1,170,309,120 B、2,724,466,688 B；共享 RTX 4050 Laptop 整卡显存 6,141 MiB、已用 3,735 MiB；RAM 可用最低 906,969,088 B。该短时常驻采样不代表最低配置或长期并发能力，板卡遥测不等同整机电量。原件见 docs/experiments/20261111_local_resources/baseline.json。

原创性与许可

复用 SenseHome/openvela 原型及第三方运行时，新增联合路由、健康观测适配、动作保护和证据流水线。上游代码、补丁和本项目新增代码分开说明；最终依赖以 compliance/NOTICE、许可证与 CURRENT_DEPENDENCIES.md 为准。模型名称和第三方产品名用于准确标注来源，不将其宣称为自主知识产权。

生成式 AI 使用说明

使用生成式 AI 辅助代码、测试、文档、图表和视频脚本制作，使用本机语音合成制作演示旁白。自动化核验包括构建、原始结果复算、格式与渲染检查，不能替代参赛者的事实复核。最终参赛者须审阅并对数据真实性、原创性、引用与提交内容承担责任。

七 附录与复核索引

材料	复核内容
evidence/network_compute/20261111_fused/	r3 构建、测试、六类实验、原始行、审计与哈希
docs/experiments/autodl_20261103_normalized_v2/	真实模型 20 条、模型配置、原始响应与重新标注
docs/experiments/20261111_fused_real/reviewed_20_sealed_repeat3/	本机正式联测 240 条、配置、逐条响应、事件与摘要
evidence/current/dashboard/	旧版 160 条本地路径、模拟状态及事件
docs/video/v2/software_replay.json	2026-11-03 历史软件回放，非 r3 现场录屏
compliance/	上游与第三方许可、NOTICE、补丁
dist/final/20261111/	本版方案、答辩、佐证与视频

结论与待验收条件

当前交付形成可运行、可解释、可回放的家庭推理路由软件。联合网络与算力在指定合成矩阵中改善合同达标；HTTP 压力场景收益有限，迟滞没有提高达标率。本机真实模型联测已形成 240 条记录，正常健康条件下未证明联合优势。后续取得真实需求、目标设备、独立网络和成本证据后，再评估生产部署与推广。

参考依据与公开对标

参考依据

1 ITU-R Recommendation M.2160-0，Framework and overall objectives of the future development of IMT for 2030 and beyond，2023。仅用于IMT-2030方向定位。

2 官方附件1作品提交要求、附件2场景设计方案大纲与评分标准。方案PDF、答辩PDF、佐证合并PDF，演示MP4为3至5分钟。

3 本项目上述原始数据、构建与审计文件。历史真实模型、r3合成回放、HTTP桩及模拟设备分别计量。

4 Home Assistant官方Assist、本地pipeline、Ollama、AI agent与OpenAI文档；RouteLLM官方仓库；ETSI MEC。2026-11-11读取，URL、摘录与支持范围见docs/value/public_sources.json。对标与成本复算见docs/value/，未开展同条件竞品性能测试。

公开对标资料仅用于证明技术路径和已有能力。尚未开展竞品同条件性能测试，不发布“优于Home Assistant”或套用RouteLLM节费比例。

本项目需求、部署与成本工具：docs/value/demand_and_benchmark.md、ai6g_mapping.md、five_minute_trial.md、deployment_and_replication.md、cost_model.md。真实回答、实际成本和试点证明尚未取得，继续以原始采集为验收条件。

补充 预注册程序组合留出检查

在生产实现、提示词、校准与配置冻结后，按 seed=2026111126 生成 12 条无原文交集的程序标签命令，先注册后推理，只运行一次。四臂各 3 次重复共 144 行，真实模型 POST 为 132 次，0 跳过、0 运行器异常。缺房间 H09 共 12 行直接走规则，不调用模型。

策略	非空模拟完成	空目标无动作且状态不变	保护拒绝
固定小模型	21/24	12/12	9
第二本机 4B	24/24	12/12	6
仅网络	21/24	12/12	9
联合	21/24	12/12	9

H05 要求开卧室灯、关客厅窗帘。小模型把窗帘关闭写为 off，而动作合同要求 close；3 次重复、3 个臂共 9 条非空任务被白名单 422 拒绝，失败全部保留，结果产生后未再调优。本矩阵不支持联合策略质量更高。

标签来自程序组合，未经人工逐条核对；这不是人工语言保留集或真实用户试用。重复请求相关，空目标保护不代表澄清话术正确。两个模型仍共享本机 GPU，设备为 PC 模拟状态。

注册先于运行，11 项源码/二进制、数据、校准与配置哈希相符。来源：docs/experiments/20261111_fused_real/holdout_12_preregistered/registration.json 及 holdout_12_programmatic_repeat3/；四套结果独立统计，导航见 sealed_evidence_index.json。

附图 架构与业务流程

图中设备为PC模拟状态，两个模型候选当前共享本机资源；接口可适配wrapper或OpenAI兼容服务。



图1 部署角色与后端适配边界

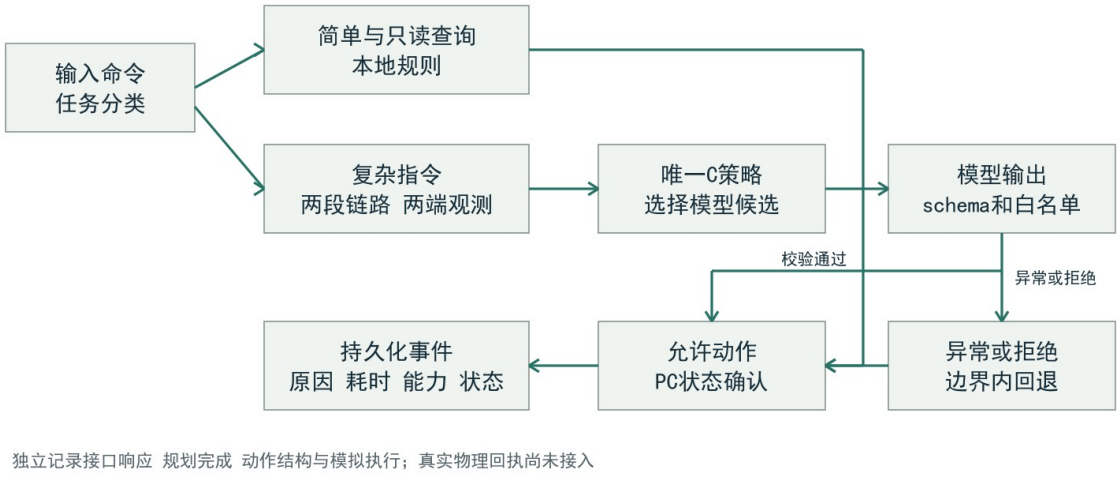


图2 任务路由 计划校验 状态执行与事件记录

动作被拒绝、后端异常与规则能力不足分别记录；具有接口响应不等于任务完成。