6G 链路自适应家庭 AI 推理系统

SenseHome　场景设计方案

任务分级 两段链路 两端算力

可解释降级与可复核运行证据

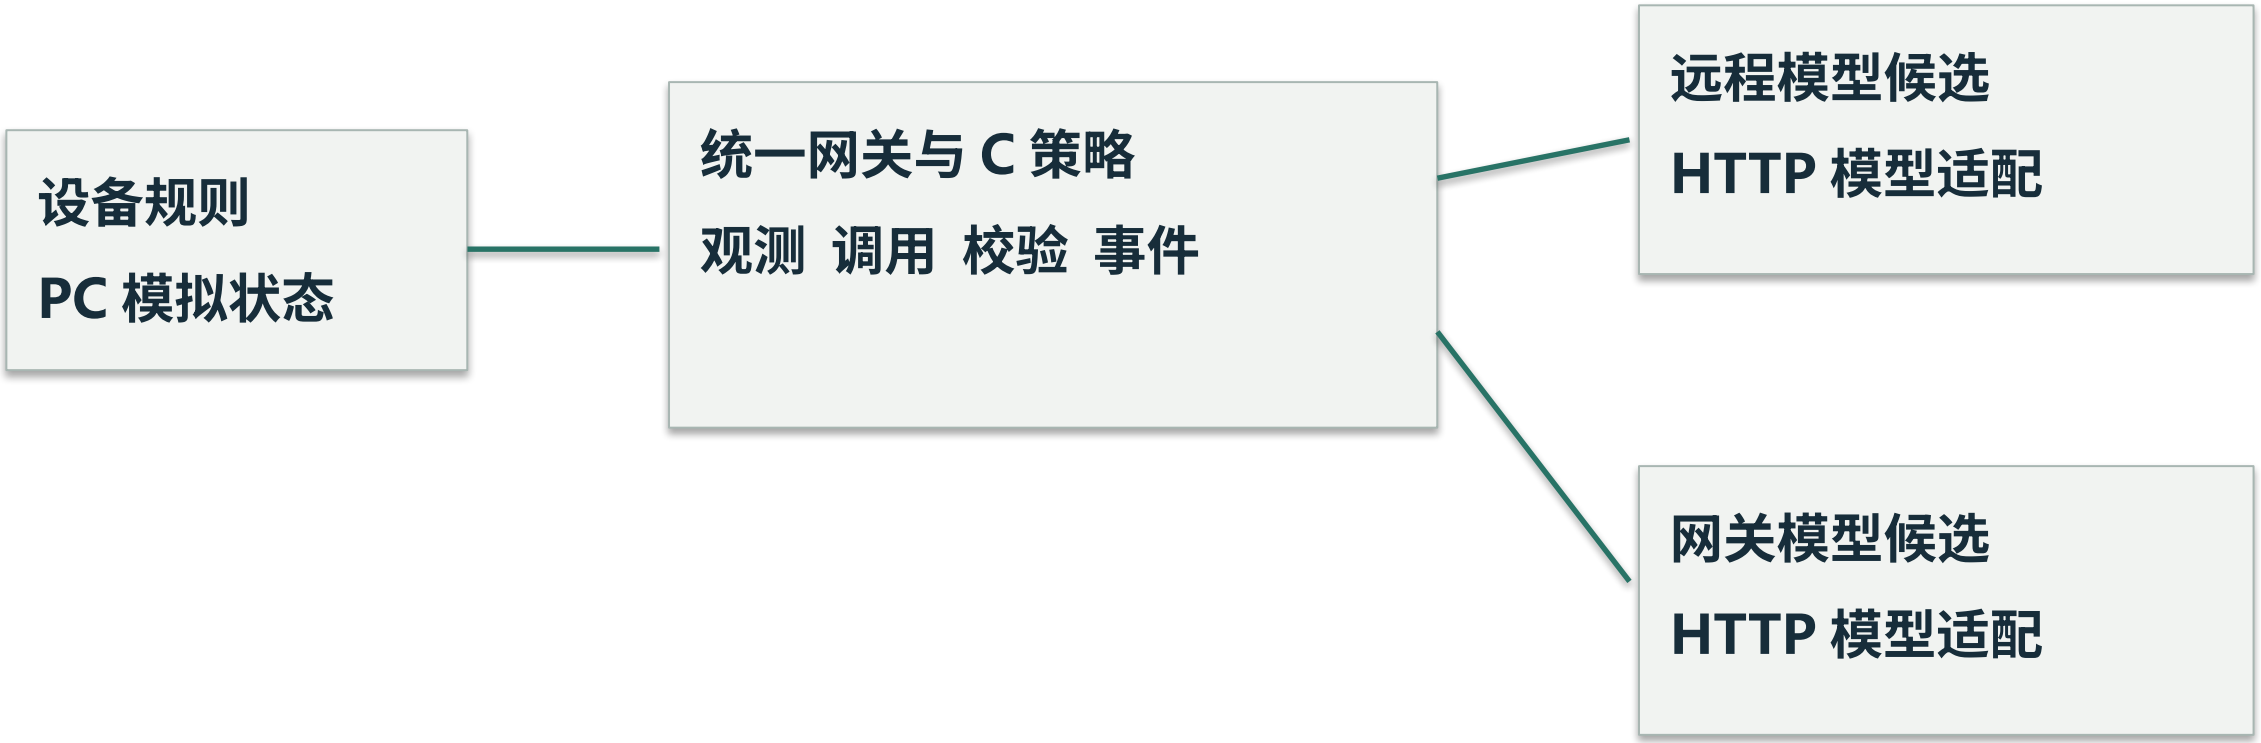
家庭模型控制的连续性需求

需求对象 存量住宅的家居集成服务商

WAN 异常时保留 LAN 与本地控制能力

模型负载与动作合规同样影响完成

设备规则 网关模型 远程模型



WAN 与 LAN 分别观测，模型网关与设备 MCU 分别核算

复杂指令联合使用链路与算力

任务约束优先 简单控制与只读查询留在规则路径

候选先验收 健康、观测年龄、队列、内存、并发

仅计算已知成本 unknown 保持未知

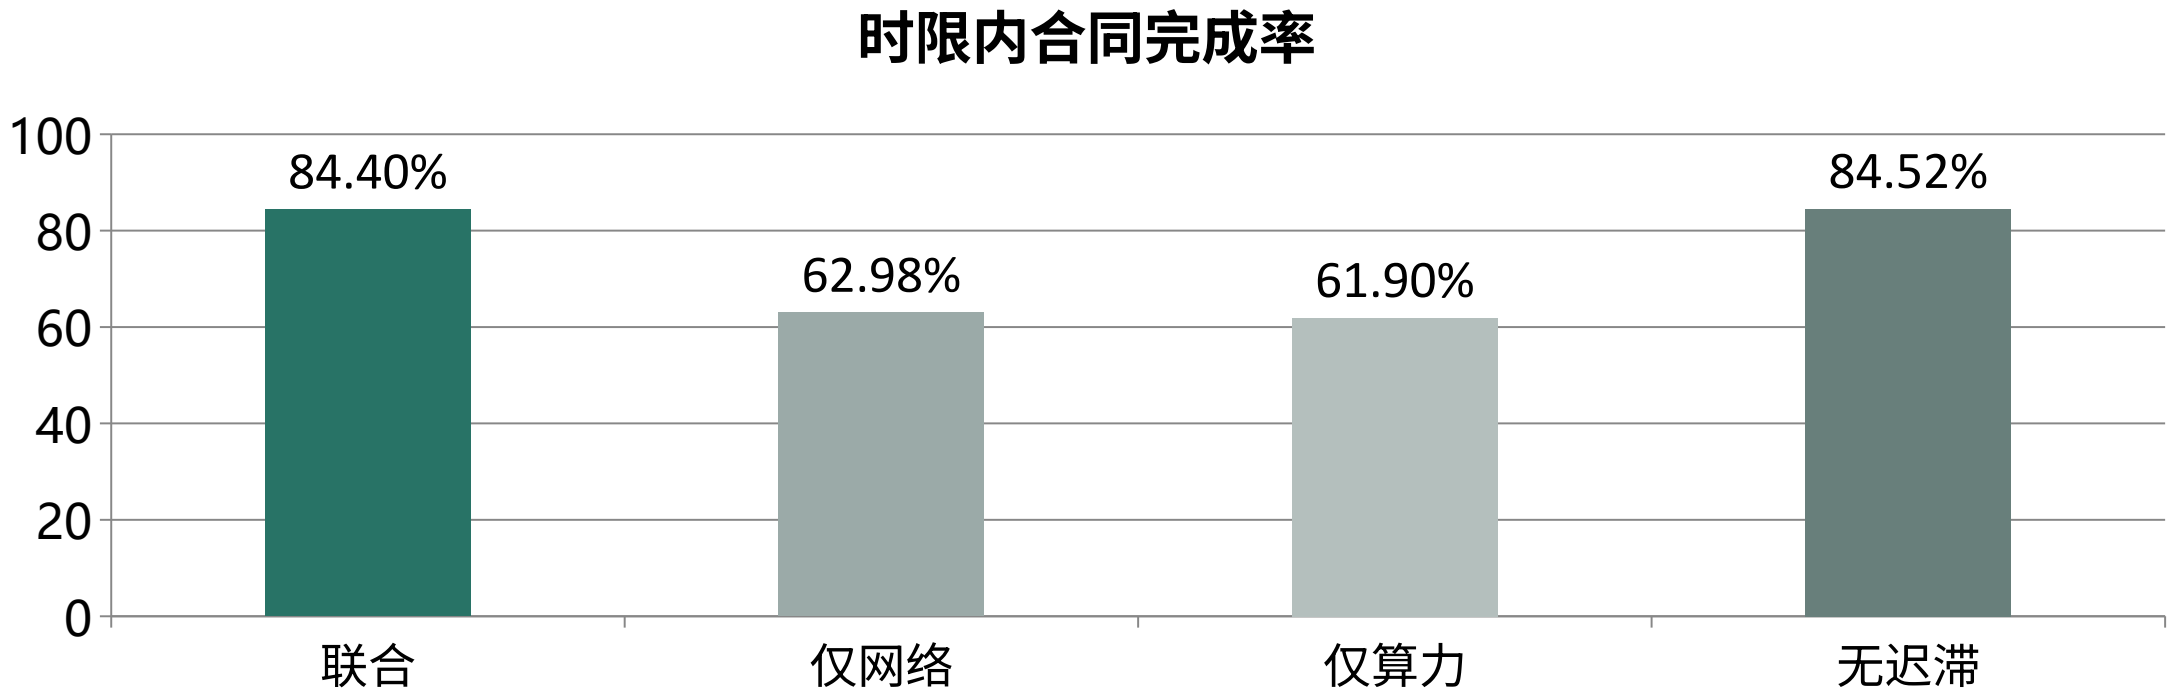
C 策略唯一决策 网关负责适配、校验和记录

证据分层计量

证据层	规模	可以回答的问题
合成回放	58,800 条	指定轨迹下的策略合同
HTTP 规划桩	9,084 请求	本机网关墙钟与事件完整性
历史真实模型	20 条	参考动作一致与接口时延
本机真实联测	240 条	四臂、 3 重复、模拟状态完成
PC 状态确认	160 请求	本地控制模拟状态变化

接口响应、合同完成、模型动作一致和物理执行采用不同定义

合成复杂任务达标率



迟滞没有提高完成率，联合仍有 786 条未解析

每臂 n=5,040 。固定规划桩与建模时延，不是 NLU 准确率

HTTP 压力条件下收益有限

本机 HTTP 实验	joint	network-only
矩阵复杂任务达标	80.95%	61.90%
压力组达标	52.98%	52.54%

679 条合同未完成，外层响应均为 200

296 条下游 503 为注入故障，区别于实网丢包

矩阵 2,940 请求与压力 6,144 请求独立统计

独立真实模型已有 20 条记录

指标	结果
HTTP 成功 / 参考动作一致	17/20 / 17/20
请求中位数 / p95	290.679 / 522.643 ms
预期拒答	3/3 另列

Qwen2.5-1.5B-Instruct RTX 4080 SUPER

标签冻结后重标原响应，未伪称重新推理

本机四臂已完成 240 条联测

复杂模型臂	结构匹配	非空模拟完成	保护拒绝
固定小模型	15/21	15/21	6
第二本机 4B 代理	18/21	15/21	3
仅网络	15/21	15/21	6
联合	15/21	15/21	6

每臂另 39 条规则请求， 18 个空结构不称澄清正确

正常健康条件下没有证明联合策略优势

同机共享 GPU ，无真实 WAN ； 20 命令 ×3 重复 ×4 臂，失败 0 、跳过 0

动作保护与状态回放

28 项安全用例 25 项拒绝 3 项正向控制

模型计划先校验，拒绝后不执行局部危险动作

软件回放展示开灯、只读查询、拒绝与关灯

回放使用历史原始 JSON 状态，编辑节奏不代表执行时延

AI 与 6G 的接口位置

融合接口	软件已实现	后续实网验收
链路预算支持推理	WAN/LAN 观测进入决策	真实遥测与尾时延
任务分级支持协同	安全和结构化任务本地优先	调用量与传输量
资源观测支持路由	健康、队列、内存、并发	真实资源校准

IMT-2030 方向映射；无 6G 空口、切片或确定性承载实测

部署与价值采用逐层验收

本机双模型 RSS 中位约 1.17 GB 与 2.72 GB

共享显存已用 3,735 MiB ，短时采样不代表最低配置

成本模型含硬件、电量、调用、维护与网络

必要成本未知则总额为 null ，不发布实测节费比例

单人实现与版本保障

当前一名学生 策略、网关、实验和材料

r3 全量测试通过，运行期间源码未变化

328 个运行文件逐路径 SHA256 一致

公开来源、原始结果与生成材料逐项对应

可运行的家庭推理路由软件

已完成 融合策略、网关闭环、原始证据与审计

新增 240 条本机真实模型联测，正常条件无联合优势

待验收 真实需求、独立网络、物理设备与成本

交付 代码、固定输入、逐条结果与复核入口