01

6G 链路自适应的家庭 AI 推理卸载系统

SenseHome · 场景设计答辩

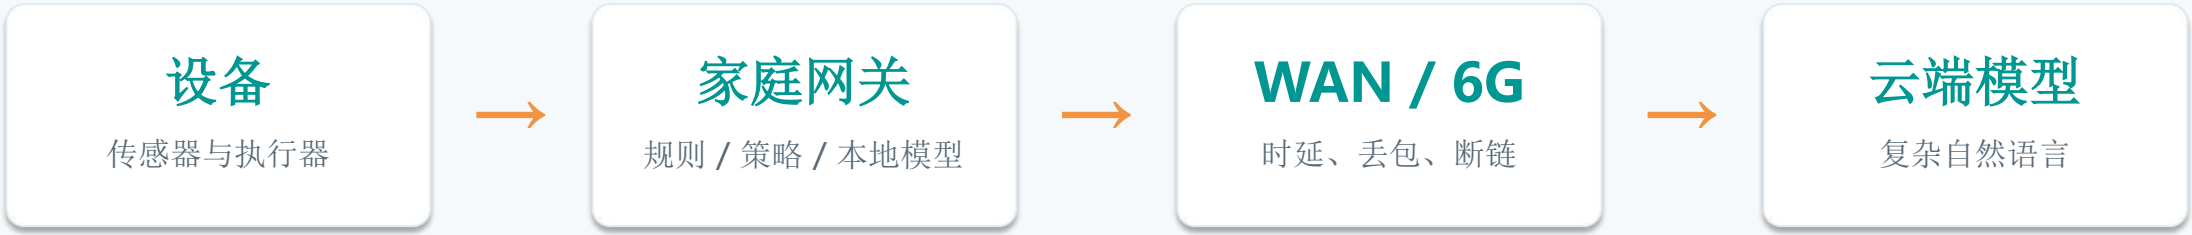
把链路状态变成家庭 AI 的运行时决策输入

从“全有或全无”变成可解释的降级阶梯

真实业务问题

面向中小型智能家居集成服务商的可预期服务水平

用户说“有点冷”时，网络状态变化，控制入口如何保持可用？



- 广域网劣化会把自然语言请求一起拖慢或拖死
- 集成商需要可解释的降级路径，而不是单一云端开关

证据口径：PC/QEMU/TCP 链路模拟；真实模型、6G 空口与物理设备待验证

场景边界与证据边界

先把“已验证”和“待验证”分开

已完成

- 端到端网关接线
- C 策略作为唯一决策实现
- 四档链路台架与 480 条记录
- 故障回退、安全白名单、可复现构建

待验证

- 真实云端 / 网关模型语义精度
- 真实 5G / 6G 空口与网络切片
- 真实家庭试点与物理执行器
- 采购成本与规模化压力

证据口径：PC/QEMU/TCP 链路模拟；真实模型、6G 空口与物理设备待验证

总体架构

策略层位于家庭网关，观测、决策、执行各自留痕



offload_policy.c：唯一决策实现

Python 网关只负责观测传递、后端调用、动作白名单和事件记录

证据口径：PC/QEMU/TCP 链路模拟；真实模型、6G 空口与物理设备待验证

七行决策表

任务类型先定安全边界，链路与算力再决定候选后端

任务	WAN / LAN 状态	后端	原因
安全关键	任意	local-rules	TASK_IS_SAFETY
结构化控制	任意	local-rules	TASK_IS_SIMPLE
复杂 NLU	WAN 达标	cloud-model	WAN_OK
复杂 NLU	WAN 劣化、LAN 可用	local-model	WAN_RTT_HIGH / WAN_UNREACHABLE
复杂 NLU	LAN 不可达	local-rules	LAN_DOWN
任意	模型不可用或超载	降级一级	计算健康约束

安全任务不因网络状态变化而放宽白名单。

证据口径：PC/QEMU/TCP 链路模拟；真实模型、6G 空口与物理设备待验证

端到端 Dashboard

展示真实 /api/command 路径的可观测字段

SenseHome Gateway • /api/command

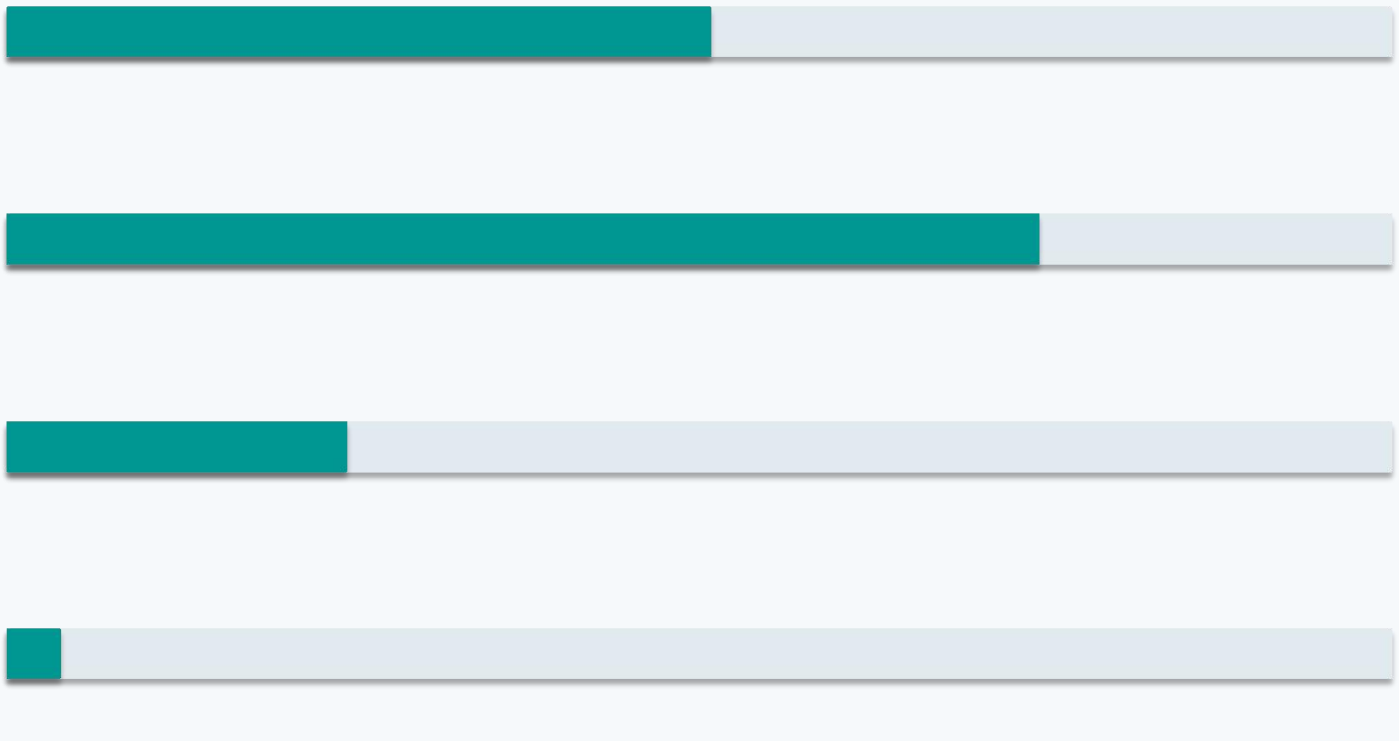
命令	客厅有点暗	任务类型	complex_nlu
链路	WAN degraded / LAN up	候选算力	**local-model**
原因码	**WAN_RTT_HIGH**	用户总时延	596.2 ms（台架）
动作	light_control / 客厅 / 60%	事件 ID	evt_20261103_00041

当前闭环：真实 HTTP 假上游 → C 策略 → 白名单 → PC 模拟 JSON 状态；仍无真实模型与物理执行器。

证据口径：PC/QEMU/TCP 链路模拟；真实模型、6G 空口与物理设备待验证

四档台架实验

同一 trace 条件下比较 adaptive 与 static-cloud



480 条原始业务记录可追溯；P4 复杂语义 0/20 是桩合同，不是模型精度测量。

证据口径：PC/QEMU/TCP 链路模拟；真实模型、6G 空口与物理设备待验证

结果如何复核

从 trace 到事件 JSONL，每条结论都能回放

01

paired_traces

每档 trace ID、seed、样本条件

→

02

events.jsonl

event_id、reason、
fallback_from、interface_ok

→

03

evidence.py

校验 meta、桩参数、summary、
来源标签

复核重点：不要把桩参数、接口成功和语义完成混成一个“准确率”。

证据口径：PC/QEMU/TCP 链路模拟；真实模型、6G 空口与物理设备待验证

故障与安全

失败时回到更低一级，并留下结构化错误

已测故障注入

- 模型进程退出
- 上游超时
- 畸形 JSON
- 远端危险动作
- prompt injection
- 32 路并发 policy CLI

安全边界

- local-rules 继续接管
- 危险动作不进入白名单
- fallback 自身异常也记录失败事件
- 真实设备联锁仍需验证

证据口径：PC/QEMU/TCP 链路模拟；真实模型、6G 空口与物理设备待验证

资源协同与 6G 价值

AI 与网络状态在网关处形成可观测闭环

AI 赋能 6G

- 端侧先行路由，减少不必要的上云请求
- 为推理负载标记任务类别与优先级
- 支持的开关灯与只读查询绕过同步探测

6G 赋能 AI

- 确定性承载为云侧推理提供预算输入
- 链路状态进入运行时决策，而非静态配置
- 网络切片与空天地协同待真实网络阶段

Dashboard 独立模拟证据：160 次请求，开关灯 p95 ≤ 4.434 ms，安防只读 p95 ≤ 1.711 ms。

证据口径：PC/QEMU/TCP 链路模拟；真实模型、6G 空口与物理设备待验证

成本与部署

先把端侧策略做小，再按模型需求配置网关

层级	实现	当前证据
端侧策略	纯 C，目标对象 text+data+bss 约 28.1 KB	历史宿主 size 记录
家庭网关	Python 网关 + 动作白名单	PC/QEMU/TCP 闭环
模型服务	AutoDL 顺序验收小、大模型	真实模型结果待接入
规模化	设备压力与采购成本	尚未测量

不承诺十元级模型网关，也不把单卡顺序实验写成双地端云部署。

证据口径：PC/QEMU/TCP 链路模拟；真实模型、6G 空口与物理设备待验证

局限与下一步

把未验证项变成下一轮可验收的工作包

当前瓶颈	P2 complex 探测中位 425.5 ms；K1/K2 原目标未达
真实模型	AutoDL 输出 p50/p95、动作正确率与失败原因
系统补证	需求、资源、外部网络、目标设备移植
安全边界	燃气、门禁等未授权控制始终拒绝执行

所有新增数字先回填 evidence schema，再进入方案正文。

证据口径：PC/QEMU/TCP 链路模拟；真实模型、6G 空口与物理设备待验证

13

6G 链路自适应的家庭 AI 推理卸载系统

SenseHome · 场景设计

把可用性、语义能力和安全边界分档管理

每次选择可解释、可回放、可回退

联系方式：待补齐 | 作品入口：待补齐